

2026/07/03 實驗報告書

這次實作了將 SAC Policy 用於 CEM 的 Policy Prior 上，並使用一樣的 MPC 演算法 rollout 同樣的 LQR system。

1. 實驗動機

驗證 Policy Prior 的品質是不是 MPC-CEM 成功的重點

2. 結論簡答

不是，而且 CEM 搭配太長的 planning horizon (也就是 H 太大) 還會破壞 Policy Prior 的品質。

3. 實驗方法

3.1 取得 SAC Policy Prior

Policy Prior 使用先前訓練好的 SAC 網路 (`sac_lqr.pt`)。該 SAC 為 **off-policy** 訓練：replay buffer 由 **MPPI** (planning horizon $H = 5$) 蒐集，SAC 再從中蒸餾出一個 reactive 的神經網路策略。其 actor 為 squashed-Gaussian，在 tanh 之前輸出 Gaussian 參數 (μ_u, σ_u) ，經過 tanh 與線性縮放後得到實際 action。

值得先注意的是：若不做任何 **planning**、純粹用這個訓練好的 **SAC policy** 做 **model-free rollout** (非 MPC 意義下)，在相同 episode ($s_0 = [1, -1, 0.5]$ 、 $T = 200$) 下其 cost-to-go 為 **2.99** (即實驗結果圖中的紅色虛線)；作為對照，最優 LQR 的 cost-to-go 為 2.47。也就是說，SAC 本身已相當接近最優。

為了把 SAC 當成「取樣分布」的先驗，我們同時取出其在 **action 空間** 的平均與標準差。設縮放係數為 `scale`、平移為 `bias`，以 delta method 對 tanh 做線性化：

$$\text{mean} = \tanh(\mu_u) \cdot \text{scale} + \text{bias}, \quad \text{std} \approx \text{scale} \cdot (1 - \tanh^2(\mu_u)) \cdot \sigma_u$$

實測 SAC 的 action std 約為 0.14 (各狀態相近)，乘上放大係數後即作為 CEM 的初始探索寬度。

3.2 Policy-Prior CEM 演算法

本次的核心修改：把 Phase II 的 CEM (`phase2.py`) 改成 `policy_prior.py`，保留 CEM 的 **refinement** 迴圈，但移除 **warm start** (不再把上一時刻收斂的計畫往前平移)，改由 **SAC policy prior** 來初始化每一個 **timestep** 的取樣分布。

在每個 timestep、給定當前狀態 s ：

1. 以 **policy prior** 初始化分布：將 SAC 的平均 action 沿著 (已知的) 確定性模型往前 rollout H 步，得到初始平均序列 $\mu \in \mathbb{R}^{H \times 3}$ ；初始標準差序列 σ 則取自各步 SAC 的 action std，並乘上 **5.0**：

$$\mu[h] = \text{SAC mean action}, \quad \sigma[h] = 5.0 \times \text{SAC action std}, \quad h = 0, \dots, H-1$$

乘上 5.0 是為了把先驗「放寬」，讓 CEM 仍保有足夠的探索空間。

2. **CEM refinement** (與 `phase2.py` 相同)：從 $\mathcal{N}(\mu, \sigma^2)$ 取樣 N 條 action 序列並 clip 到 action 邊界；用模型估計每條序列的 H -step 折扣報酬；取報酬最高的前 K 條 elites，重新擬合 μ 與 σ ；重複直到收斂 ($\|\mu - \mu_{\text{prev}}\|$ 或 $\max(\sigma)$ 低於門檻)。
3. 執行首個 **action**：執行 $\mu[0]$ ，環境前進一步，不做 **warm start**，下一個 timestep 再重新以 SAC prior

初始化。


3.3 比較基準與掃描設定

在 `compare.py` 中，讓所有控制器在完全相同的 episode (相同 env、相同初始狀態 $s_0 = [1, -1, 0.5]$ 、相同 seed) 下比較，並掃描 planning horizon $H = 1, \dots, 20$ 。共同超參數：每步取樣數 $N = 1000$ 、elites $K = 50$ 、episode 長度 $T = 200$ 、`seed=0`。

比較對象：

- **Optimal LQR**：解 DARE 得到的最優線性回授 $a = -Ks$ ，作為理論上限 (與 H 無關，畫成水平虛線)。
- **Random-shooting MPC** (Phase I)：固定 proposal 的一次性取樣。
- **CEM** (Phase II)：有 warm start、 $\sigma_{\text{init}} = 0.2$ 的標準 CEM。
- **SAC**：直接執行 SAC reactive 策略 (無 planning horizon，畫成水平虛線)。
- **Policy-Prior CEM**：本次方法 (3.3 節)。

4. 實驗結果



可以看到擁有 Policy prior 的 CEM 表現比較差就算了，甚至到 $H = 9$ 以後還低於原本的 SAC performance (紅色虛線)。這證明至少以這裡來說 CEM 就是來搞人的。具體數據如下：

H | MPC reward | CEM reward | PolPrior reward

1	-202005272151307848517681152.000	-232804925955544543412617216.000	-2838.304
2	-15.876	-2.497	-2.466
3	-50.118	-2.487	-2.466
4	-87.913	-2.491	-2.467

5	-145.643	-2.511	-2.470
6	-166.688	-2.547	-2.494
7	-234.232	-2.565	-2.573
8	-325.558	-2.566	-2.727
9	-378.057	-2.637	-3.035
10	-408.697	-2.661	-3.297
11	-455.724	-2.747	-3.736
12	-561.197	-2.871	-4.410
13	-537.112	-3.121	-5.226
14	-678.641	-3.417	-6.661
15	-722.628	-3.455	-7.406
16	-773.889	-3.629	-8.910
17	-871.651	-4.199	-10.094
18	-941.854	-4.635	-11.324
19	-915.099	-5.265	-13.688
20	-1464.449	-5.701	-15.061

Saved results to compare_results.npz

不過，在 H 夠小的時候確實有 policy prior 會好一些。